Сирачев Вильдан Ильдарович
Сухинин Виталий Максимович
Лактина Дарья Сергеевна
Брязгунова Полина Владимировна

Применение методов машинного обучения для классификации экспериментальной группы образца биологической ткани

Анализ предоставленных данных

В рамках хакатона исходные данные были предоставлены в виде трех директорий: endo, exo и control. Каждая из них содержала вложенные поддиректории, однако данная иерархия не несла содержательной информации для последующего анализа и поэтому не учитывалась. Основными единицами анализа являлись текстовые файлы формата .txt. Анализ имен файлов (например, cortex_control_1group_633nm_center1500_obj100_power100_1s_5acc_map35x15_step2_place4_1) показал, что в них закодирована информация как о типе образца, так и о параметрах регистрации. В частности, из названий файлов были идентифицированы исследуемые отделы мозга — cortex, striatum и cerebellum — а также значение координаты центрального пикселя (1500 или 2900). Было установлено, что значение этой координаты связано с различиями в диапазоне пиков на зависимости интенсивности (Intensity) от волнового числа (Wave) (рис.1 и рис.2).

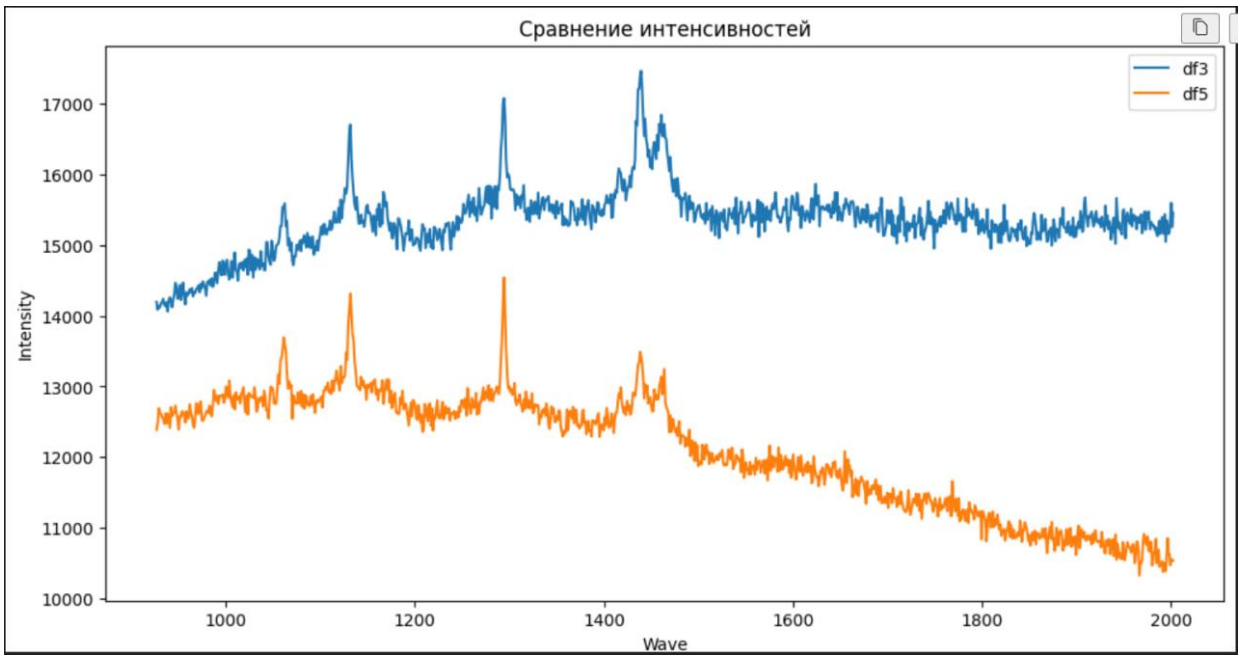

Рисунок 1 - сравнение спектров для двух точек из разных файлов с центральным пикселем 1500

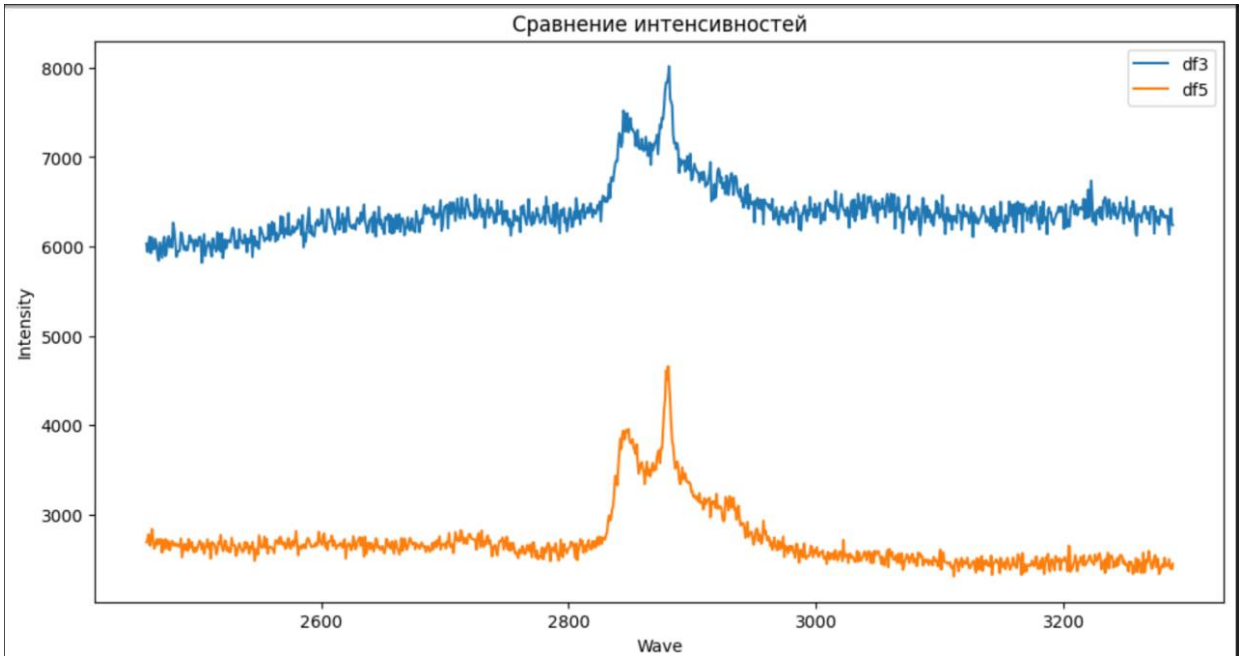

Рисунок 2 - сравнение спектров для двух точек из разных файлов с центральным пикселем 2900

Для последующей стандартизации и унификации данных был разработан парсер, преобразующий исходные файлы формата .txt в две сводные таблицы формата .csv: 1500.csv и 2900.csv. Разделение таблиц осуществлялось в соответствии со значением координаты центрального пикселя. Каждая итоговая таблица содержала следующие столбцы: wave, intensity, brain_region и class, где wave соответствовал значению волнового числа, intensity — измерецнной

интенсивности сигнала, brain_region — исследуемой области мозга, а class — экспериментальной группе образца. Class – целевая переменная. При помощи маски, ограничивающий значения wave до информативных, был сокращен объем выборки. Для последующего анализа из исходных спектров были выделены два информативных диапазона волновых чисел: 1240–1700 см$^{-1}$ для набора данных 1500 и 2380–3070 см$^{-1}$ для набора данных 2900. Выбор диапазона 1240–1700 см$^{-1}$ был обусловлен тем, что он включает область полос амид III, деформационных колебаний CH2 и амид I, широко используемых при анализе белковых и липидных компонентов биологических образцов. Диапазон 2380–3070 см$^{-1}$ охватывает высоковолновую область C–H-валентных колебаний, содержащую полосы около 2850 см$^{-1}$, 2930 см$^{-1}$ и 3015 см$^{-1}$, информативные в отношении липидной и белковой составляющих, а также ненасыщенных липидов.

Обучение модели

Рассматриваемый pipeline предназначен для обработки Raman-спектров из двух диапазонов, условно обозначенных как 1500 и 2900, без их смешивания на этапе базового препроцессинга. На выходе формируются отдельные таблицы признаков для каждого диапазона, после чего для них обучаются независимые классификационные модели.

Работа модели начинается с загрузки CSV-данных, нормализации имён столбцов и стандартизации категориальных признаков, таких как класс образца и анатомическая область мозга. После этого общая таблица разбивается на отдельные спектры: границы между ними определяются по последовательности значений wave, а каждый сегмент рассматривается как самостоятельное наблюдение.

Далее спектры классифицируются по полосам; спектры с неопределённым диапазоном отбрасываются, затем выполняется интерполяция и выравнивание для обеспечения сопоставимости данных, после этого проводится коррекция базовой линии методом AsLS для удаления фона, сглаживание и поиск локальных максимумов, интерпретируемых как пики.

Для каждого спектра вычисляются глобальные характеристики сигнала, включая площадь под кривой, среднее значение интенсивности, стандартное

отклонение, асимметрию, эксцесс, энергию сигнала и спектральную энтропию. Отдельно рассчитываются признаки, связанные с пиками: их число, положение, выраженность, ширина и параметры, агрегированные по заранее определённым окнам. Целевая переменная кодируется отдельно, а категориальные поля преобразуются в числовой формат перед обучением.

После подготовки признаков датасет делится на обучающую, валидационную и тестовую части с использованием стратифицированного разбиения, что позволяет сохранять структуру классов в разных подвыборках. Далее для файлов 1500_preprocessing.csv и 2900_preprocessing.csv обучаются отдельные модели RandomForestClassifier. Для каждой модели сохраняются метрики качества (табл.1 и табл.2), матрицы ошибок и служебные артефакты, необходимые для воспроизводимого применения на новых данных.

Таблица 1 - метрики качества для модели model1500

split	n_rows	accuracy	macro_f1
train	33061	0.8479	0.8464
valid	7097	0.8446	0.8433
test	7092	0.7204	0.7164

Таблица 2 - метрики качества для модели model2900

split	n_rows	accuracy	macro_f1
train	38951	0.8373	0.8385
valid	8348	0.8394	0.8379
test	8351	0.6496	0.6437

Далее модель улучшается: для этого задаются различные наборы признаков, после чего выполняется оценка значимости признаков методом их последовательного исключения. Таким образом, финальная конфигурация выбирается эмпирически как компромисс между устойчивостью классификации и информативностью признакового пространства.

Дополнительно ноутбук оценивает важность признаков двумя способами: через встроенные важности леса и через permutation importance. Это позволяет интерпретировать, какие характеристики спектра вносят наибольший вклад в итоговое решение классификатора.

Использование обученной модели

Обученные модели были сериализованы и сохранены в формате joblib, после чего интегрированы в backend разработанного веб-приложения. Серверная часть приложения включает каталог models с сохранёнными моделями, а также Python-модули для предобработки спектров, извлечения признаков и классификации. Пользователь взаимодействует с системой через web-интерфейс (рис.3), загружая спектральный файл, выбирая диапазон волновых чисел и область мозга; далее backend выполняет обработку данных и возвращает результат классификации ткани.

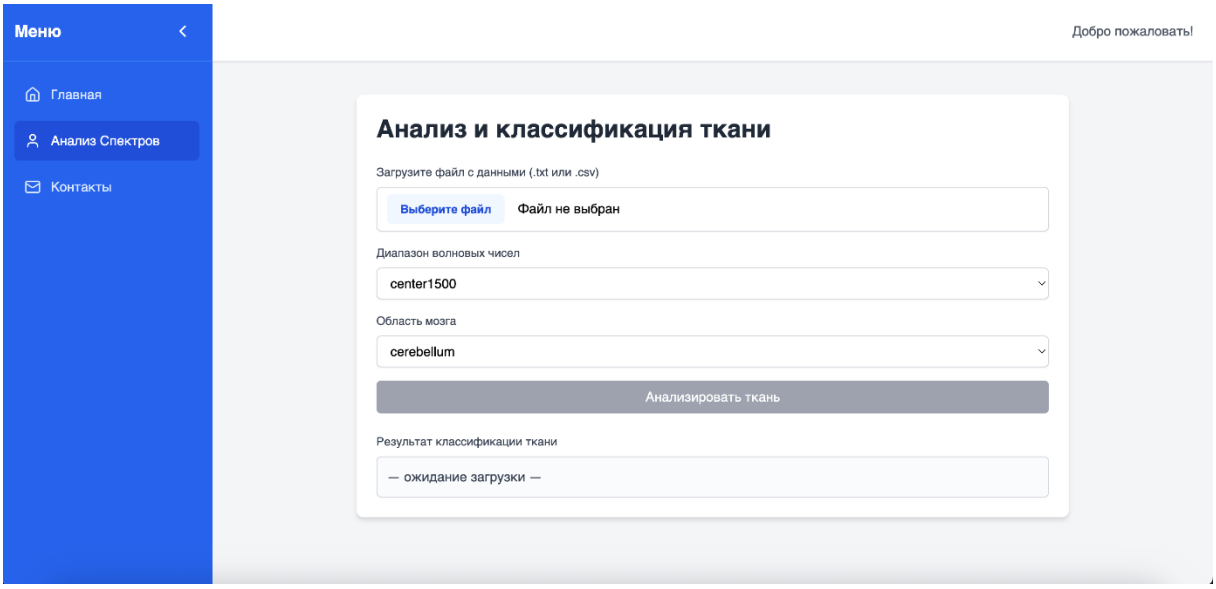

Рисунок 3 - пользовательский интерфейс